

Diagnóstico de defeitos lineares em células fotovoltaicas de silício policristalino baseado em rede neural convolucional usando imagens de eletroluminescência

Wuqin Tang, Qiang Yang, Xiaochen Hu, Wenjun Yan.

Resumo: A demanda global por energia elétrica vem aumentando gradualmente ao longo dos anos. Para supri-la, investimentos vêm sendo realizados na geração de energia através de fontes renováveis, dentre as quais a energia solar fotovoltaica (FV). O crescimento da capacidade instalada de fontes de geração FV traz demandas por métodos sofisticados e precisos para a detecção de falhas nas células que compõem tal sistema. A eletroluminescência (EL) é considerada uma técnica eficiente para a avaliação da qualidade de módulos FV por meio da observação das características internas das células. A maioria dos defeitos celulares exibe as características lineares nas imagens EL que podem evoluir gradualmente para defeitos permanentes. No entanto, tais características lineares dificilmente podem ser identificadas nas imagens EL das células de silício policristalino ($S_i - p$) devido a fundos complexos. O artigo propõe uma solução de diagnóstico automático de defeitos lineares baseada em aprendizado profundo para células FV de $S_i - p$ com base em imagens EL. Para extração de características dos defeitos das imagens, utilizou-se o método da matriz Hessiana, juntamente com técnicas de detectores de linhas em várias escalas, obtendo-se um desempenho aprimorado. Um modelo baseado em aprendizado profundo para diagnóstico de defeitos também é proposto. A solução apresentada é extensivamente avaliada através de experimentos, comparando-se com modelos de aprendizado de máquina disponíveis na literatura (V_{gg} 16, ResNet50 e InceptionV3). Os resultados numéricos demonstram a eficácia e superioridade da solução proposta.

Keywords: Electroluminescence images; Defects classification; Feature extraction; Deep learning.

Palavras-chaves: Imagens de eletroluminescência; Classificação de defeitos; Extração de atributos; Aprendizado profundo.

1. INTRODUÇÃO

A preocupação com as mudanças climáticas e a redução gradativa dos recursos fósseis estimula a busca por alternativas de geração de energia limpa e de menor impacto ao meio ambiente. Neste cenário os sistemas Fotovoltaicos (FV) vêm sendo amplamente empregados na produção de energia. As estatísticas da Agência Internacional de Energia (IEA) indicaram que a capacidade fotovoltaica instalada em 2019 ultrapassou 627 GW e a última previsão de 5 anos da IEA mostra que a capacidade fotovoltaica total chegará a 1209 GW até 2024 (IEA, 2019). Na prática, os módulos são frequentemente observados com várias formas de defeitos. O defeito pode ser introduzido no processo de fabricação, transporte e instalação do módulo. Além disso, as infraestruturas de geração FV são geralmente instaladas e operadas em locais remotos sob condições ambientais severas que podem levar a mais defeitos do módulo.

Técnicas de identificação de defeitos em sistemas FVs são alvo de grande estudo na literatura, tendo em vista que a existência de defeitos nos módulos podem degradar diretamente a eficiência da geração de energia em grandes parques FVs ou ainda gerar prejuízos severos e irreversíveis (Li et al., 2019). A identificação dos defeitos nos módulos pode se dar através da análise das curvas de corrente

e tensão (I/V), verificação da temperatura dos sistemas através de técnicas de termografia e verificações visuais do próprio sistema. Dos métodos citados anteriormente, nenhum deles é capaz de verificar defeitos lineares e intrínsecos do módulo ou célula FV, isso faz com que certos defeitos sejam observados tardiamente, sem a possibilidade de reversão do problema.

Atualmente a eletroluminescência (EL) tornou-se uma técnica muito utilizada para detecção de defeitos por efeito EL na indústria FV. O efeito EL ocorre porque a recombinação irradiativa de portadores pode criar emissão de luz quando a corrente é ejetada em um módulo. As soluções de detecção e análise de defeitos de módulos baseados em EL forneceram uma abordagem eficiente para a avaliação de módulos FV, recebendo cada vez mais atenção na avaliação da qualidade do módulo e na inspeção de grandes instalações FVs em operação. Por outro lado, os defeitos do módulo linear, por exemplo, mini-rachadura, interrupção do dedo, são considerados comumente disponíveis em fazendas FVs atuais que podem levar a pontos quentes e falhas do módulo. Tais defeitos que possuem formas ou limites de linha podem ser observados como linhas ou regiões mais escuras na imagem EL (Dhimish et al., 2017), conforme ilustrado na Fig 1.




Figura 1. Diferentes formas de defeitos lineares: (a) interrupção do dedo; (b) trincas; (c) rachadura e interrupção do dedo

Os módulos FVs são formados através da conexão de células FVs ligadas em série por meio de fitas de interconexão denominadas de Busbars, conforme ilustrado na Fig 2. A potência gerada pelo módulo será a soma da potência gerada por todas as células. Isso significa que ao analisar os defeitos nas imagens EL, estaremos observando os defeitos a nível de célula. As duas categorias de células mais utilizadas em módulos FVs são baseadas em silício monocristalino ($S_i - m$) e policristalino ($S_i - p$).




Figura 2. A estrutura interna do módulo FV : (a) strings em um módulo; (b) uma célula em uma string.

A Figura 3 ilustra as imagens EL dos módulos de $S_i - m$ e $S_i - p$ e as correspondentes distribuições de intensidade. Pode ser visto que a distribuição de densidade na célula de silício policristalino (Figura 2(g) e Figura 2(h)) exibem características mais complexas do que a monocristalina (Figura 2(e) e Figura 2(f)). A característica de defeitos em $S_i - p$ mais difícil de extrair. No entanto, é caro coletar amostras de imagens EL eficazes e rotulá-las na realidade.

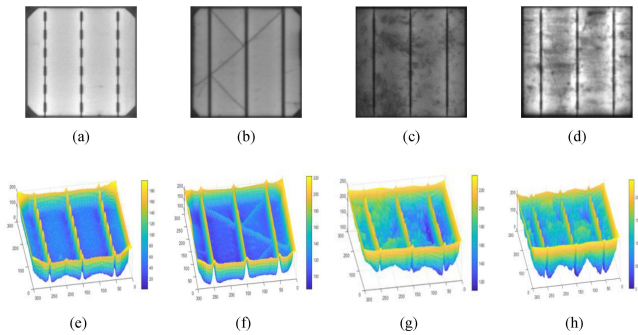


Figura 3. Comparação de células de $S_i - m$ e $S_i - p$. (a) $S_i - m$ sem defeitos; (b) $S_i - m$ com defeitos; (c) $S_i - p$ sem defeitos; (d) $S_i - p$ com defeitos; (e-h) é a distribuição de densidade correspondente.

Observa-se que as imagens das células de $S_i - p$ possui um fundo que pode dificultar o diagnóstico da classificação até mesmo por algoritmos de aprendizado profundo mais robustos. Por tanto, a detecção e análise de defeitos lineares eficientes e precisos do módulo FV baseado em $S_i - p$ usando imagens EL ainda é considerada uma tarefa não trivial. O trabalho propõe um algoritmo trifásico para solução automática de diagnóstico de defeitos lineares em células FVs de $S_i - p$ utilizando as imagens EL, que combina o tradicional processamento de imagens e técnicas de aprendizado profundo.

O artigo está organizado da seguinte forma: A Seção 2 apresenta uma visão geral do método proposto para a detecção dos defeitos das células. A Seção 3 mostra as características do extrator de recursos baseado em matriz Hessiana aprimorada através do detector de linha que é descrito na Seção 4. A Seção 5 apresenta o modelo baseado em *Deep Learning* (DL) para a detecção automática dos defeitos. Os resultados obtidos são apresentados na Seção 6 e por fim as considerações conclusivas são apresentadas na Seção 7.

2. VISÃO GERAL DO MÉTODO PROPOSTO

A estrutura geral para a análise dos defeitos das células FVs no trabalho proposto se dá em duas etapas principais, a saber:

- Coleta de imagens EL através da inspeção em campo ou inspeção de fábrica onde as imagens coletadas são transferidas para o centro de dados e centro de computação através de uma rede de comunicação.
- Implementação dos algoritmos de extração e detecção de defeitos. Os algoritmos contêm três procedimentos (algoritmo trifásico) para detectar os defeitos nas imagens EL, conforme ilustrado na Figura 4.

As características de defeitos nas imagens EL brutas são extraídas e aprimoradas pelo método baseado em matriz hessiana e baseado em detector de linha multi-escala, que é apresentado na primeira e segunda linha da Figura 4, respectivamente. Finalmente, as imagens processadas são enviadas para o modelo baseado em aprendizado profundo para detecção automática dos defeitos, conforme apresentado na terceira linha da Figura 4.

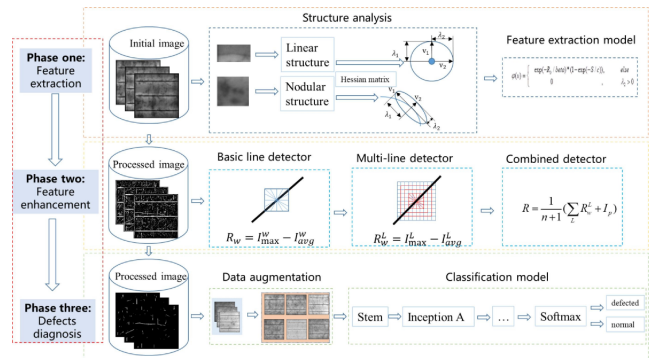


Figura 4. Visão geral do sistema de detecção e análise de defeitos do módulo FV baseado em EL.

3. MÉTODO DE EXTRAÇÃO DE CARACTERÍSTICAS DE DEFEITOS BASEADOS EM MATRIZ HESSIANA

A extração dos atributos das imagens em EL das células FVs exige um tratamento diferenciado, tendo em vista que as imagens possuem um fundo complexo. Para que fosse possível distinguir fundo de defeito, adotou-se a matriz hessiana em conjunto com o método de contorno ativo baseado em regiões da imagem.

O filtro baseado em matriz hessiana é usado para analisar os autovalores de cada pixel na matriz e pode descrever a característica da estrutura da imagem. A ideia por trás disso é extrair a direção principal decompondo a estrutura local de segunda ordem da imagem. O elemento $H(u)$ da matriz na posição $u = (x, y)$ pode ser calculado por (1)

$$H(u) = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} \quad (1)$$

Onde $\frac{\partial^2 f}{\partial x^2}$, $\frac{\partial^2 f}{\partial x \partial y}$, $\frac{\partial^2 f}{\partial y \partial x}$ e $\frac{\partial^2 f}{\partial y^2}$ são as derivadas parciais de segunda ordem de $f(u)$ e $H(u)$ é uma matriz definida positiva. λ_1 e λ_2 são os autovalores de $H(u)$ e os autovetores correspondentes são representados por v_1 e v_2 .

Conforme sugerido em (Chen et al., 2020), os autovalores e autovetores podem descrever a anisotropia da mudança da imagem e a diferença entre os dois autovalores pode representar a estrutura potencial, conforme ilustrado na Figura 5




Figura 5. Anisotropia da imagem representada pelos autovalores e autovetores.

Na Figura 5(a) e 5(b) respectivamente, observa-se uma estrutura em círculo (ponto azul) e uma curva em azul. A estrutura do círculo azul denota as estruturas do tipo nodular e a curva azul representa as estruturas em forma de linha nas imagens. λ_1 e λ_2 são os autovalores e, v_1 e v_2 são os autovetores correspondentes.

Os autovalores podem ser calculados através de (2) e (3), a seguir:

$$\lambda_1 = K + \sqrt{K^2 - Q^2} \quad (2)$$

$$\lambda_2 = K - \sqrt{K^2 - Q^2} \quad (3)$$

Onde:

$$K = (f_{xx} + f_{yy})/2, Q = \sqrt{f_{xx}f_{yy} - f_{xy}f_{yx}} \quad (4)$$

4. APRIMORAMENTO DE CARACTERÍSTICAS DO DEFEITO BASEADO EM DETECTOR DE LINHA MULTIESCALA

O método proposto na Seção 3 ainda não é confiável o suficiente para detecção automática dos defeitos nas células FVs, tendo em vista que as estruturas nodulares são caracterizadas como estruturas lineares. Visando melhorar a classificação, logo o trabalho propõe um detector linear para o aprimoramento das características dos defeitos.

Projetou-se uma janela de tamanho $M \times M$ em cada píxel da imagem, representando o nível de cinza médio por I_{avg}^M , onde doze linhas de comprimento L cruzam o píxel, com uma diferença de 15° entre elas, conforme ilustrado na Figura 6. O nível de cinza de cada linha na janela pode ser calculado e o valor máximo do nível de cinza é indicado por I_{max}^L , onde a resposta da linha de comprimento L na janela M pode ser calculada da seguinte forma:

$$R_M^L = I_{max}^L - I_{avg}^M \quad (5)$$

Onde $1 \leq L \leq M$. Os defeitos nas imagens EL são mais escuros que o fundo, isso quer dizer que se os pixels pertencerem a área defeituosa, R_M^L será maior, sendo menor, caso os pixels das imagens não seja caracterizado como defeituosas.




Figura 6. O operador de detecção multiescala.

Na Figura 6, cada retângulo azul representa o píxel em uma imagem e a linha preta representa o defeito linear na área. As doze linhas vermelhas são linhas detectoras para calcular a resposta, onde o comprimento das linhas pode variar de 1 a M . Três retângulos amarelos com diferentes comprimentos laterais são usados para calcular a resposta em diferentes escalas. A resposta em um píxel de uma escala diferente pode ser calculada por (6).

$$R = \frac{1}{n+1} (\sum_L R_M^L + P) \quad (6)$$

Onde n é o número de escalas aplicadas e P é o valor do píxel na posição correspondente. Os resultados do aprimoramento de recursos são mostrados na Figura 7.

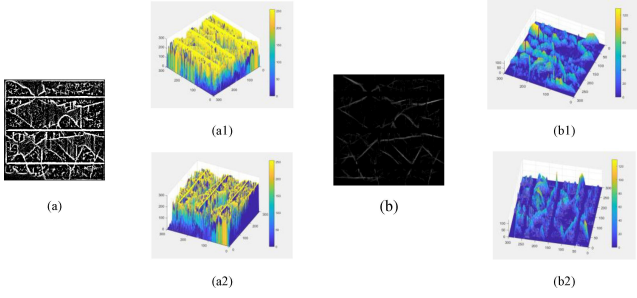


Figura 7. Resultados da comparação entre a imagem processada por extração de características e aprimoramento de características: (a), (b) são os resultados usando o método das Seções 2 e 3; (a1-2) e (b1-2) são as distribuições numéricas tridimensionais da imagem correspondente de duas vistas laterais diferentes.

5. MODELO BASEADO EM DEEP LEARNING PARA DIAGNÓSTICO DE DEFEITOS DO MÓDULO

Nos últimos anos, vários modelos de classificação baseados em DL foram desenvolvidos nas mais variadas áreas de atuação, como por exemplo, V_{GG} (Simonyan e Zisserman, 2015), GoogleNet (Szegedy et al., 2015) e ResNet (He et al., 2016).

O objetivo desta Seção é propor uma rede leve para obter um desempenho comparável ou ainda melhor para o diagnóstico de defeitos em imagens EL, que pode obter um melhor equilíbrio entre complexidade e precisão em comparação com outros modelos baseados em aprendizado profundo.

5.1 Arquitetura do modelo proposto

Considerando as características dos modelos de classificação baseados em DL citados anteriormente, optou-se por utilizar as arquiteturas *Inception4* e *Inception-ResNet-v2* (Szegedy et al., 2016) como os pilares do modelo proposto no referido trabalho. Além disso o modelo contém vários blocos diferentes, incluindo bloco *Stem*, bloco *Inception-A*, bloco *Reduction-A* e bloco *Inception-C*. Todo o esquema do modelo é apresentado na Figura 8.




Figura 8. Todo o esquema do modelo de classificação proposto.

O esquema detalhado dos blocos *Inception-A*, *Inception-C*, *Reduction-A* da Figura 8 é apresentado na Figura 9. Considerando o alto desempenho dos blocos Inception, comprovado em (Szegedy et al., 2016), a estrutura interna dos blocos Inception não foi alterada. Em cada bloco, conforme apresentado na Figura 9, existem várias operações de convolução e agrupamento com diferentes parâmetros para extrair as características das imagens.




Figura 9. Todo o esquema do modelo de classificação proposto.

O efeito de classificação para os defeitos na imagem EL do bloco no Inceptionv4 é analisado por vários experimentos na Seção 6.

5.2 Metodologia do treinamento

Durante o processo de treinamento, utilizou-se o otimizador *Stochastic Gradient Descent (SGD)*. A função de perda de entropia cruzada é adotada para descrever o grau de convergência. Durante o processo de treinamento, os pesos no modelo foram constantemente atualizados e os parâmetros de treinamento estão listados na Tabela 1.

Tabela 1. Parâmetros de treinamento do modelo de detecção de defeitos desenvolvido.

Descrição	Símbolo	Valor
Tamanho do batch	b_s	64
Taxa de Aprendizagem	η	$1e-3$
Queda do peso	λ	0.01

6. RESULTADOS EXPERIMENTAIS E AVALIAÇÕES

O diagnóstico de defeitos nas células FVs de *Si - p* baseadas em DL, foram realizadas através de comparações do modelo proposto com outras topologias disponíveis na literatura. O desempenho com diferentes configurações de parâmetros nos modelos propostos também é amplamente analisado.

6.1 Configurações experimentais

Neste trabalho, o conjunto de dados de imagens EL contém três partes: a primeira parte contém 300 imagens fornecidas por (Deitsch et al, 2019), a segunda parte contém 200 imagens fornecidas pela JinkoPower Company (Xangai, China) e a parte três contém 500 imagens, que foram coletadas durante a inspeção de campo real nas fazendas reais em três locais diferentes na China (10 MW em Ruicheng, província de Hebei, 5 MW em Hangzhou, província de Zhejiang e 10 MW em Taizhou, Província de Hainan). O conjunto de dados foi dividido em três partes, conforme apresentado na Tabela 2.

As imagens no conjunto de dados de treinamento também são usadas para gerar 2.100 imagens EL pelo método de aumento (Tang et al, 2020) para cada tipo de defeito e as imagens no conjunto de validação e teste são duplicadas por reflexão, rotação e flip.

Para os experimentos, a extração linear de recursos e o aprimoramento de recursos de defeitos (Seções 3 e 4) são implementados em Matlab e o modelo de diagnóstico de defeitos de células é implementado em Python (Pytorch 1.6.0) baseado em uma plataforma de computação com 4 GPUs NVIDIA TITAN.

Tabela 2. Número de imagens EL para cada conjunto de dados ($m \times n \times l$), m é o número de imagens iniciais, n é o número de tipos de defeito, l significa que o tamanho do conjunto de dados aumenta l vezes pelo aumento de dados.

Conjunto de dados	Tamanho do conjunto de dados
Conjunto de treinamento	$700 \times 2 \times 3$
Conjunto de validação	$100 \times 2 \times 2$
Conjunto de teste	$200 \times 2 \times 2$

6.2 Avaliação do processo de treinamento

Nesta seção, o desempenho do diagnóstico linear do defeito é avaliado e os resultados são apresentados na Figura 10. Pode-se observar que a acurácia e perda de desempenho no treinamento e validação se configuram durante o processo de treinamento. A precisão média de cerca de 0,98 e 0,93 pode ser alcançada no conjunto de treinamento e validação, respectivamente.




Figura 10. Avaliação de desempenho do modelo durante o processo de treinamento.

O valor mais alto da precisão no conjunto de validação pode ser obtido na 47ª época e quando a época continua a aumentar, há uma ligeira diminuição em termos de precisão. Isso pode ser causado pelo problema de ajuste excessivo. Portanto, para obter um melhor desempenho no diagnóstico de defeitos, os parâmetros do modelo são salvos na 47ª época para reduzir a probabilidade de sobreajuste.

6.3 Estudos de Caso

Neste trabalho foram realizados 04 estudos de caso, tendo como objetivo a avaliação extensivamente da solução algorítmica proposta e apresenta os resultados numéricos. O impacto da extração de características e diferentes configurações de parâmetros no modelo proposto também é avaliado e analisado. Os dois principais estudos de casos são discutidos a seguir:

Caso 3: Comparação de desempenho com os métodos existentes.

Nesse caso, o desempenho do modelo proposto para classificação é comparado com os modelos $VGG-16$, Inceptionv3 (Szegedy et al., 2015), ResNet50 (He et al., 2016), NASNet-A (Zoph et al., 2018), AmoebaNet-A (Real et al., 2019), PNASNet (Liu et al., 2018). Todos os modelos são treinados com os conjuntos de dados apresentados na Seção 6.1 Tabela 2. Para avaliar o desempenho do método, apresentamos a acurácia em diferentes conjuntos de dados na Figura 11. Pode-se observar que a solução proposta pode obter a maior precisão para detecção de defeitos

com os parâmetros mínimos em comparação com outras topologias.

Performance comparison with other models using the combined data augmentation method.

	ResNet50	InceptionV3	VGG16	NASNet-A	AmoebaNet-A	PNASNet	Proposed solution
Total Params	26 M	24 M	40 M	89 M	87 M	86 M	5 M
Accuracy in different datasets	Part one	0.88	0.88	0.87	0.92	0.91	0.93
	Part two	0.87	0.88	0.86	0.91	0.92	0.92
	Part three	0.86	0.86	0.85	0.9	0.92	0.91

Figura 11. Comparação de desempenho com outras topologias usando o método de aumento de dados combinado.

Conclui-se que o método proposto pode obter um excelente desempenho para a detecção de defeitos em módulos fotovoltaicos com a imagem EL e o melhor compromisso entre o desempenho de classificação e complexidade computacional.

Caso 4: Comparação de desempenho com diferentes tamanhos de conjuntos de dados.

Por fim, avaliou-se o desempenho dos algoritmos propostos para diferentes conjuntos de dados disponíveis no Dataset. O resultado da acurácia juntamente com o aumento do número de amostras é apresentado na Tabela 3. Observa-se que quando o conjunto de dados atinge 500 amostras para cada tipo de condição, o desempenho se torna estável.

Tabela 3. Precisão junto com os diferentes tamanhos de conjuntos de dados (cada condição).

Nº de Amostras	100	200	300	400	500	600	700
Precisão	0.72	0.81	0.85	0.89	0.93	0.93	0.93

7. CONCLUSÕES E TRABALHOS FUTUROS

Neste trabalho, um sistema baseado em EL para detecção de defeitos em módulos FVs baseados em $Si-p$ é projetado. Inicialmente foi proposto um extrator linear de características do defeito das células. Em seguida, o recurso extraído foi aprimorado por um detector de linha adicional. A distribuição numérica da imagem foi simplificada pelo extrator e aprimoramento de recursos, aumentando a precisão do diagnóstico automático de defeitos e diminuindo a demanda pelo conjunto de dados para treinamento. Também foi proposto um modelo de rede baseada em aprendizado profundo para diagnóstico de defeitos, que obtém um melhor equilíbrio entre complexidade e precisão em comparação com outros modelos disponíveis na literatura. Ao final, um conjunto de experimentos é implementado para mostrar a excelência do método proposto.

Para trabalhos futuros, considera-se que várias direções no domínio da EL podem ser pesquisadas. Em primeiro lugar, mais tipos de defeitos e vários defeitos coexistentes no módulo FV precisavam ser considerados para avaliar o estado de integridade do módulo FV. O modelo proposto pode ser implantado nos Veículos Aéreos Não Tripulados (VANTS) para realizar a detecção dos defeitos durante a inspeção de fazendas FVs de grande escala.

REFERÊNCIAS

Akram M. W., Li Guiqiang. Improved outdoor thermography and processing of infrared images for defect detection in PV modules. Solar Energy, 190(2019), pp. 549–560.

Chen, H., Zhao, H., Han, D., et al. (2020). Structure-aware-based crack defect detection for multicrystalline solar cells. *Measurement*, 151.

Deitsch, S., Christlein, V., Berger, S., et al. (2019). Automatic classification of defective photovoltaic module cells in electroluminescence images. *Solar Energy*, 185, 455–468.

Denio H. Aerial solar thermography and condition monitoring of photovoltaic systems. *IEEE Proceeding of the 38th photovoltaic. Spec. Conference* (2012), pp. 000613–000618.

Dhimish, M., Holmes, V., Mehrdadi, B., et al. (2017). The impact of cracks on photovoltaic power performance. *Journal of Science: Advanced Materials and Devices*, 2, 199–209. Frangi, R. F., Wiro, J. N., et al. (1998). Multiscale vessel enhancement filtering. *Lecture Notes in Computer Science*, 1496(1998), 130–137.

Fraza, M., Silva, J.A, Lobato K., etc. Electroluminescence of silicon solar cells using a consumer grade digital camera. *Measurement*, 99(2017), pp. 7–12.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas (pp. 770–778).

Xiaobo, H., et al. (2019). Diagnosis of GaAs solar-cell resistance via absolute electroluminescence imaging and distributed circuit modeling. *Energy*, 174, 85–90.

Hui, H., Gao, C., Yue, Z., et al. (2018). Polycrystalline silicon wafer defect segmentation based on deep convolutional neural networks. *Pattern Recognition Letters*, 130. IEA, (2019). *Renewables 2019: Market analysis and forecast from 2019 to 2024*. IEA.

Jerman T., Pernu's F., Likar B., et al., (2015). Beyond Frangi: an improved multiscale vesselness filter. *Medical Imaging 2015: Image Processing*. International Society for Optics and Photonics, 9413.

Jin, J., Yang, L., Zhang, X., et al. (2013). Vascular tree segmentation in medical images using hessian-based multiscale filtering and level set method. *Computational and Mathematical Methods in Medicine*.

Johnston, S. (2015). Contactless electroluminescence imaging for cell and module characterization. In *2015 IEEE 42nd Photovoltaic Specialist Conference (PVSC)* (pp. 1–6).

Juan R. O. S., Kim J. (2020). Photovoltaic Cell Defect Detection Model based-on Extracted Electroluminescence Images using SVM Classifier. *2020 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC)*, Fukuoka, Japan, pp. 578–582.

Szegedy C., Ioffe S., Vanhoucke V. (2016). Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning. *CoRR*, abs/1602.07261.

Tang, W., Yang, Q., et al. (2020). Deep learning based automatic defect identification of photovoltaic module using electroluminescence images. *Solar Energy*, 453–460.